學號：B07902006 系級：資工二 姓名：林則仰

1. (20%) Policy Gradient 方法

   a. 請閱讀及跑過範例程式，並試著改進 reward 計算的方式。

   b. 請說明你如何改進 reward 的算法，而不同的算法又如何影響訓練結果？

   改進reward方式：

   原本範例 code 中的 reward 算法是將每個 action 的 reward 都以整個遊戲的 reward (total reward) 來代替，但如同教授在影片中所說，這樣來計算每個action 的 reward 是不合理的，對於第 i 個 action ，應該只要考慮第 i 個action ~ 遊戲結束前的最後一個 action 所得到的reward。此外，對於第 i 個 action 而言，對越後面的 action 應該影響力越低，因此應該要有一個 discount 的算法來衡量這件事。最後我參考了教授影片中的公式，也就是將原本的 $R(\tau^n)$ 改成：

   $$\sum_{t'=t}^{T_n} \gamma^{t'-t} r_{t'}^n$$

   並將參數 γ 設為0.99、EPISODE_PER_BATCH = 10、NUM_BATCH = 1000。而在改進算法過後，訓練結果出現了大幅進步：

   （藍色線為範例code 的結果，橘色線為加入 discount 算法的結果）

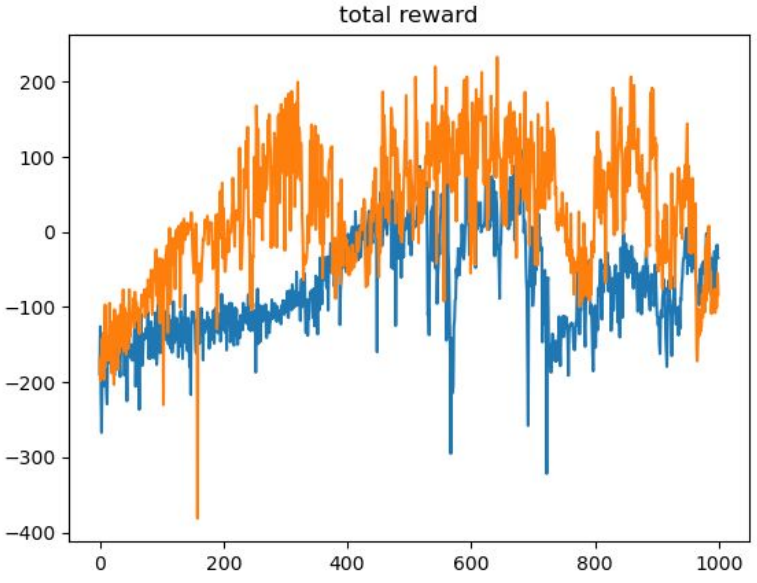

可以發現範例 code 會在num_batch大約等於500時才漸漸開始得到大於0的reward，而加入 discount 算法的 code 約在 num_batch=250 時就開始得到大於0的 reward整體而言橘色線都在藍色線之上，意味著使用discount 算法的 code 大致都有著較好的結果。

2. (30%) 試著修改與比較至少三項超參數（神經網路大小、一個 batch 中的回合數等），並說明你觀察到什麼。

我試著改變了三項超參數，分別是神經網路大小、EPISODE_PER_BATCH、以及所選用的optimizer。神經網路的部分，我將原本的神經網路中間又加了兩層，分別是nn.Linear(16, 32) 及 nn.Linear(32, 64) ，使得神經網路架構更大。在EPISODE_PER_BATCH的部分，我從原先的 5 調整到10，最後一個實驗是將optimizer 由助教給的 SGD 改成 Adam (lr = 0.003)。下表為三者各自與原先的sample code 在 total reward 的差異（藍色線皆為 sample code）：

改變神經網路大小	EPISODE_PER_BATCH	改變 optimizer
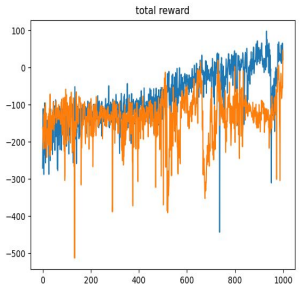	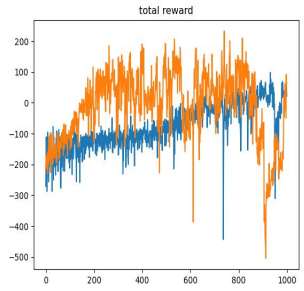	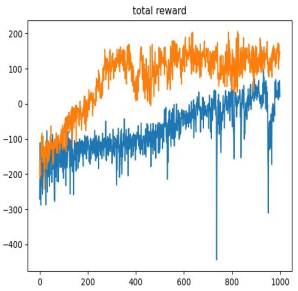

（一）改變神經網路

從上圖可以發現，增加了神經網路的規模後，不但沒有變好的趨勢，反而在total reward 的 performance 上比原先較小的網路更差。我認為有兩種可能：一是我還不瞭解這種遊戲比較適合怎麼樣的網路架構來做訓練，因此盲目的加大神經網路的大小反而無益，二是可能這個遊戲本來就不適合使用較為複雜的網路，畢竟它本身就不是一個有很多變數的遊戲，因此將神經網路複雜化反而可能使他在訓練的表現上得到反效果。

（二）增加每個 batch 的回合數

由上圖可知，增加每個 batch 的回合數大致可以使表現更好，更重要的是在一次更新內玩越多次遊戲，就可以使 total reward 變成正值的速度越快，由圖也可以發現一開始兩者的曲線幅度是有很大的差距的。

（三）改變optimizer

這一組的比較就更為明顯，在前1000個batch中，使用Adam 作為 optimizer明顯在 total reward 的表現比使用 SGD來得更好。因為 Adam 有收斂較快的特性，因此理論上確實在前面更新的部分確實會比 SGD 來得更加優異，但若是更新到比較後面時，也許SGD的方法就比較能逼近收斂點。

3. (20%) Actor-Critic 方法

    a. 請同學們從 REINFORCE with baseline、Q Actor-Critic、A2C 等眾多方法中擇一實作。

    b. 請說明你的實做與前者（Policy Gradient）的差異。

    在這一題的實作中，我選擇了 reinforce with baseline 的方法（與 policy gradient 實作出來數據的差異會在下一題呈現，此題僅說明 Actoe-critic 實作與 policy gradient 的差異。），而 Actor-Critic 與 policy gradient 的最大差別就是 Actor-Critic 的方法比原先的policy gradient 多了 Critic 的角色。Critic 會基於 Actor 所採取的 action 給分，也就是 Critic 會判斷這次的 action 是不是一個好的行動，如果是才在 gradient ascent 時更新的多一點，反之則 ascent 地少一些。另外，在這個方法中加入 baseline 的概念，使得學習的成長速度更快，而且曲線的波動幅度也較小。因此，如助教投影片的 pesudo-code 所示，兩者實作的差異就是增加一個baseline，並每次都由 minimizing baseline 與 reward 的 distance (L1_loss) 去 refit baseline。

4. (30%) 具體比較（數據、作圖）以上幾種方法有何差異，也請說明其各自的優缺點為何。

    首先比較 policy gradient 與 Actor-Critic 在實作上有何差異以及各自的優缺點：

<table>
<tr>
<td> 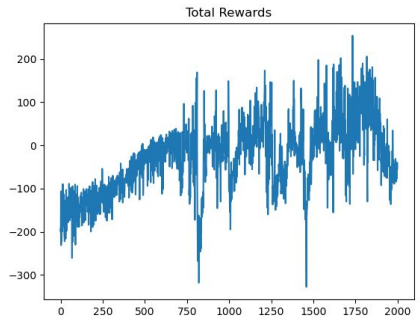
</td>
<td> 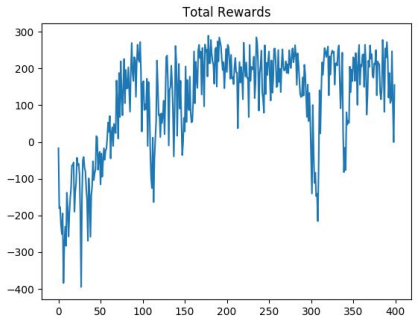
</td>
</tr>
<tr>
<td>policy gradient</td>
<td>Actor-Critic</td>
</tr>
</table>

    由上圖可以發現，除了一開始Actor-Critic 有較大幅度的震盪，甚至一度快掉到-400分以外，在 total rewards 的表現上明顯 Actor-Critic 優於

policy gradient 。更驚人的是，在num_batch = 50左右時，Actor -Critic 的模型就已經能漸漸地得到大於0的 total reward，並在 num_batch = 100時就已經能達到接近 250 分的高分，這樣的學習速度明顯要比傳統policy gradient 好上數倍！

而兩者的差異已經在第三題大略說明完畢，在反覆查詢了網路上的一些資料過後，發現policy gradient 的優點在於他在收斂方面的能力是較好的、較容易實現隨機的策略、並在高維空間的計算中更為有效。但其缺點也是顯而易見：不易收斂至全域最佳值，容易收斂到局部最大值 (local maximum) 上，另一個缺點是policy gradient 為走完一個回合才更新，效率較差。

至於Actor-Critic，因為是由 policy gradient 演化而來，其Actor部分繼承了 policy gradient 的優點，並能夠完成單步更新，以增加學習的效率。缺點在於新增的 Critic 部分，其模型架構相當難收斂，因此可能較難達到最佳值。

接著比較第一題方法的優缺點（作圖已附在第一題中）：

使用 discount 算法的優點當然是可以使每個 action 的 reward 更能夠貼近其真正造成的影響，可以使訓練的過程中 total reward上升較快。缺點是其與原本的算法相比，似乎在 total reward 的震盪明顯地較大，我猜測可能是因為每次都乘上固定的 gamma 值，因此會使得系統較為不穩定。仔細查詢相關資料後，找到網路上也有相關的論文給出了相對應的解決方法，如逐漸增加 discount factor γ 直至最終值等，亦能有效降低過擬合等現象。

最後來比較第二題方法的優缺點（作圖已附在第二題中）：

大致上優缺點已經在第二題中敘述的差不多了，增加網路的大小優點在於能夠適應更複雜的問題及考慮更多參數，缺點是不見得適用於某些情形（如這次的作業）。而增大每個 batch 的回合數能夠使訓練的過程中玩到更多次遊戲，因此在訓練的速度上也會呈現正相關。最後是改變 optimizer 的部分，這次我只是選擇了較常使用的 Adam 來做嘗試，並且與預期中的結果相符，使用Adam 的優點為收斂較快、能較好的處理稀疏的梯度等等...，而缺點在不考慮訓練時間的情形下，可能沒辦法像SGD一樣有那麼好的收斂至全域最佳點的能力。